

Grundlagen: Datenbanken

Zentralübung / Wiederholung / Fragestunde

Linnea Passing

Harald Lang

gdb@in.tum.de

WiSe 2017 / 2018

Diese Folien finden Sie online.

Die Mitschrift stellen wir im Anschluss online.

Agenda

- ▶ Hinweise zur Klausur
- ▶ Stoffübersicht/-Diskussion
- ▶ Wiederholung + Übung
 - ▶ Mehrbenutzersynchronisation
 - ▶ Erweiterbares Hashing
 - ▶ Anfragebearbeitung/-optimierung
 - ▶ Datenbankentwurf
 - ▶ Relationale Algebra
 - ▶ Relationale Entwurfstheorie

Hinweise zur Klausur

Termine

- ▶ 1. Klausurtermin - **Mi. 28.02.2018, 8:00 bis 9:30 Uhr**
- ▶ Notenbekanntgabe / Anmeldung zu Einsicht - **Mi. 7.03.2018 (ab Mittag)**
- ▶ Einsicht - **Do. 8.03.2018 (Nachmittags)**
- ▶ Anmeldung zur 2. Klausur von - **ab 10.03.2018, bis ... ? (TBA)**
- ▶ 2. Klausurtermin - **TBA**

Verschiedenes

- ▶ **Raumbekanntgabe**, via TUMonline sowie in Moodle
- ▶ 90 Minuten / 90 Punkte
- ▶ Sitzplatzvergabe (Aushang: $\text{MatrNr} \mapsto \text{Sitzplatz}$, KEINE Namensnennung)
- ▶ Betrugsfälle
- ▶ Notenbekanntgabe
- ▶ Einsichtnahme (Instruktionen in Moodle, nach Notenbekanntgabe)
- ▶ Bonus: Gilt für beide Klausuren.

Stoffübersicht (1)

Datenbankentwurf / ER-Modellierung

- ▶ ER-Diagramme, Funktionalitäten, Min-Max, Übersetzung ER \leftrightarrow Relational, Schemavereinfachung/-verfeinerung

Das Relational Modell

- ▶ Stichworte: Schema, Instanz/Ausprägung, Tupel, Attribute,...
- ▶ Anfragesprachen
 - ▶ Relationale Algebra
 - ▶ RA-Operatoren: Projektion, Selektion, Join (Theta, Natural, Outer, Semi, Anti), Kreuzprodukt, Mengendifferenz/-vereinigung/-schnitt, Division
 - ▶ Tupelkalkül, ~~Domänenkalkül~~
nicht prüfungssrelevant

Stoffübersicht (2)

SQL

- ▶ ...

Relationale Entwurfstheorie

- ▶ Definitionen:
 - ▶ Funktionale Abhängigkeiten (FDs), Armstrong-Axiome (+Regeln), FD-Hülle, Kanonische Überdeckung, Attribut-Hülle, Kandidaten-/Superschlüssel, Mehrwertige Abhängigkeiten (MVDs), Komplementregel, Triviale FDs/MVDs,...
- ▶ Normalformen: 1., 2., 3.NF, BCNF und 4. NF
- ▶ Zerlegung von Relationen
 - ▶ in 3.NF mit dem Synthesealgorithmus
 - ▶ in BCNF/4.NF (zwei Varianten des Dekompositionsalgorithmus)
 - ▶ Stichworte: Verlustlos, Abhängigkeitsbewahrend

Stoffübersicht (3)

► **Physische Datenorganisation**

- ▶ Speicherhierarchie
- ▶ HDD/RAID
- ▶ TID-Konzept
- ▶ Indexstrukturen (Bäume, Hashing)

► **Anfragebearbeitung**

- ▶ Kanonische Übersetzung (SQL → Relationale Algebra)
- ▶ Logische Optimierung (in relationaler Algebra)
 - ▶ Frühzeitige Selektion, Kreuzprodukte durch Joins ersetzen, Joinreihenfolge
- ▶ Implementierung relationaler Operatoren
 - ▶ ...
 - ▶ Nested-Loop-Join
 - ▶ Sort-Merge-Join
 - ▶ Hash-Join
 - ▶ Index-Join

Stoffübersicht (4)

► Transaktionsverwaltung

- ▶ BOT, read, write, commit, abort
- ▶ Rollback (R1 Recovery)
- ▶ ACID-Eigenschaften

► Fehlerbehandlung (Recovery)

- ▶ Fehlerklassifikation (R1 - R4)
- ▶ Protokollierung: Redo/Undo, physisch/logisch, Before/After-Image, WAL, LSN
- ▶ Pufferverwaltung: Seite, FIX, Ersetzungsstrategie steal/ \neg steal, Einbringstrategie force/ \neg force
- ▶ Wiederanlauf nach Fehler, Fehlertoleranz des Wiederanlaufs, Sicherungspunkte

► Mehrbenutzersynchronisation

- ▶ Formale Definition einer Transaktion (TA)
- ▶ Historien (Schedules)
 - ▶ Konfliktoperationen, (Konflikt-)Äquivalenz, Eigenschaften von Historien
- ▶ Datenbank-Scheduler
 - ▶ pessimistisch (sperrbasiert, zeitstempelbasiert), optimistisch

Mehrbenutzersynchronisation

Transaktionen (High-Level)

- ▶ Ein Programm, das auf einem Datenbestand arbeitet.
 - ▶ Beispiele: Banküberweisung, Online-Bestellung, Ausleihe (Bib.)
- ▶ Daten werden gelesen, verarbeitet (Programmlogik) und geschrieben.

Atomarität

- ▶ Eine Transaktion überführt eine Datenbank von einem konsistenten Zustand in einen wiederum konsistenten Zustand.
- ▶ Zwischenzeitlich kann die Datenbank in einem inkonsistenten Zustand sein.
- ▶ Atomarität (*Alles-oder-nichts-Eigenschaft*):
 - ▶ Es werden entweder alle Änderungen übernommen, oder keine.
 - ▶ Schlägt während der Ausführung eine Operation fehl, werden alle bisherigen Änderungen in den Ausgangszustand zurück gesetzt.

A atomicity
C consistency
I isolation
D durability

Transaktionen (aus Sicht des Datenbanksystems)

Eine Transaktion T_i besteht aus folgenden **elementaren Operationen**:

- $r_i(A)$ - **Lesen** des Datenobjekts A
- $w_i(A)$ - **Schreiben** des Datenobjekts A
- a_i - **Abort** (alle Änderungen rückgängig machen)
- c_i - **Commit** (alle Änderungen festschreiben)

Die letzte Operation ist entweder ein **commit** oder ein **abort**.

Die dahinterliegende Programmlogik ist hier nebensächlich.

Historie (Schedule)

Eine Historie spezifiziert eine **zeitliche Abfolge von Elementaroperationen** mehrerer **parallel laufender Transaktionen** (verzahnte Ausführung).

$$H = \underline{r_1(A)}, \underline{r_2(C)}, \underline{w_1(A)}, \underline{w_2(C)}, \underline{r_1(B)}, \underline{w_1(B)}, \underline{r_2(A)}, \underline{w_2(A)}, c_1, c_2$$

T_1 T_2

Eine Historie umfasst nicht zwangsläufig eine totale Ordnung ALLER Operationen, aber mindestens die der **Konfliktoperationen**.

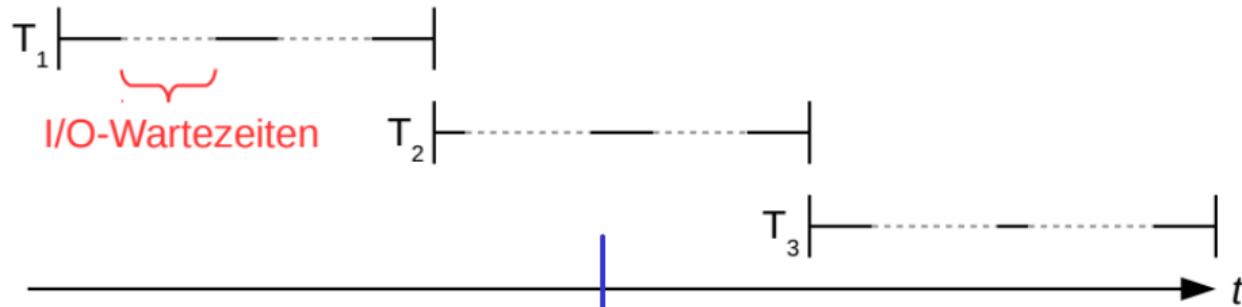
Konfliktoperationen

Zwei Operationen (verschiedener aktiver Transaktionen) auf dem selben Datum stehen zueinander in Konflikt, gdw. mindestens eine Operation schreibend ist.

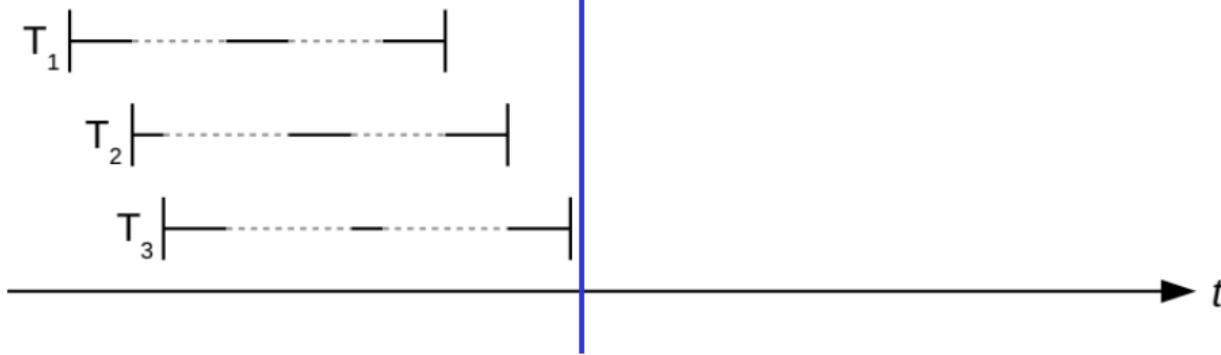
- ▶ Unkontrollierte Nebenläufigkeit kann zu Inkonsistenzen führen:
 - ▶ *lost update*
 - ▶ *dirty read*
 - ▶ *non-repeatable read*
 - ▶ *phantom problem*

Serielle vs. Parallele Ausführung

Eine **serielle Ausführung** verhindert all diese Probleme, da zu jedem Zeitpunkt maximal eine Transaktion aktiv ist und somit keine Konflikte auftreten können.



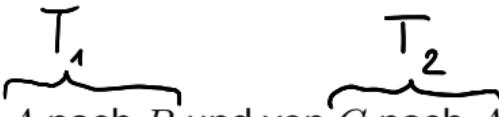
Eine verzahnte **parallele Ausführung** (im Mehrbenutzerbetrieb) ist effizienter.



Serialisierbarkeit (Konzept)

... soll die Vorteile der seriellen Ausführung (**Isolation**) mit den Vorteilen des Mehrbenutzerbetriebs (**höherer Durchsatz**) kombinieren.

Serialisierbarkeit



Beispiel (Überweisung von A nach B und von C nach A):

$$H = r_1(A), r_2(C), w_1(A), w_2(C), r_1(B), w_1(B), r_2(A), w_2(A), c_1, c_2$$

| | T_1 | T_2 |
|------------------|----------|----------------------|
| $A = A \cdot 10$ | $r_1(A)$ | |
| | $w_1(A)$ | $r_2(C)$ |
| | | <i>Konfliktoper.</i> |
| $B = B + 10$ | $r_1(B)$ | $w_2(C)$ |
| | $w_1(B)$ | |
| | | $r_2(A)$ |
| | | $w_2(A)$ |
| c_1 | | |
| t | | |

| | T_1 | T_2 |
|--|----------|----------|
| | $r_1(A)$ | |
| | $w_1(A)$ | $r_1(B)$ |
| | | $w_1(B)$ |
| | | c_1 |
| | | $r_2(C)$ |
| | | $w_2(C)$ |
| | | $r_2(A)$ |
| | | $w_2(A)$ |
| | | c_2 |

$$H' = T_1 | T_2$$

Serialisierbarkeitsgraph
 $SG(H)$:

$$T_1 \rightarrow T_2$$

kein Zyklus \rightarrow Serialisierbar

$H \equiv H'$ gdw. Konfliktoperationen in der gleichen Reihenfolge.

H ist (konflikt-) serialisierbar.

Serialisierbarkeitstheorem

H ist **serialisierbar**, gdw. $\text{SG}(H)$ azyklisch ist.

Weitere Eigenschaften von Historien

● Rücksetzbar (RC)

- ▶ Commit der schreibenden Transaktion T_j muss vor dem Commit der lesenden Transaktion T_i durchgeführt werden.
- ▶ $c_j <_H c_i$

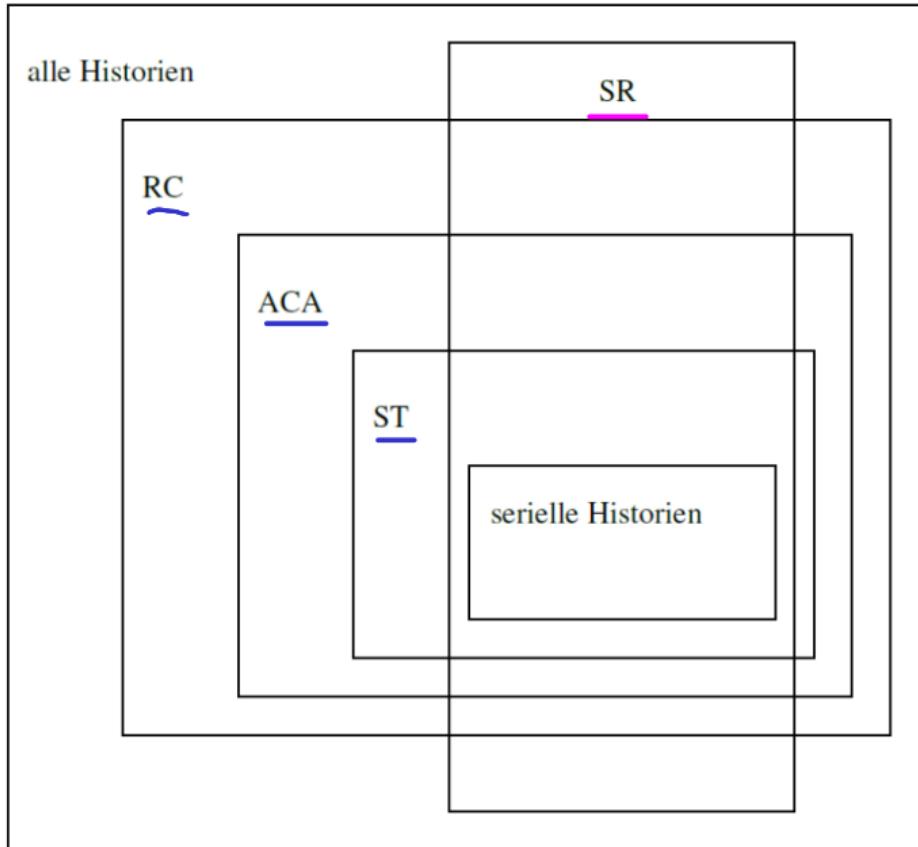
● Vermeidet kaskadierendes Rücksetzen (ACA)

- ▶ Es wird erst gelesen, wenn die Änderungen der schreibenden Transaktion T_j festgeschrieben wurden (Commit).
- ▶ $c_j <_H r_i$

● Strikt (ST)

- ▶ Wie ACA, verhindert aber zusätzlich blindes Schreiben (ohne vorheriges Lesen).
- ▶ $a_j <_H o_i$ oder $c_j <_H o_i$ (Operation $o = r$ oder w)

Eigenschaften von Historien (Zusammenhang)



Eigenschaften von Historien: Übung

RC: T_3 liest von T_2 und T_4 . $c_2, c_4 \leq_h c_2$ ✓

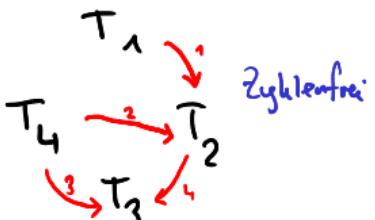
ACA: $c_2, c_4 \leq_h r_3(B)$ ✓

ST:

| $H:$ | Schritt | T_1 | T_2 | T_3 | T_4 |
|------|---------|-----------|--------|--------|--------|
| 1 | | $w(A)$ | | | |
| 2 | | | | | |
| 3 | | $\neg ST$ | $w(A)$ | | $r(B)$ |
| 4 | | | | | |
| 5 | | c | | | |
| 6 | | | | | |
| 7 | | | $w(B)$ | | |
| 8 | | | c | | |
| 9 | | | | $r(B)$ | |
| 10 | | | | $w(C)$ | |
| 11 | | | | c | |

| wahr | falsch | Aussage |
|------|--------|-------------|
| ✓ | | $H \in SR$ |
| ✓ | | $H \in RC$ |
| ✓ | | $H \in ACA$ |
| | ✓ | $H \in ST$ |

$SG(H):$

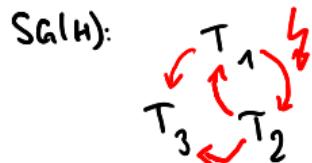


$$H = T_1 | T_4 | T_2 | T_3 \equiv T_4 | T_1 | T_2 | T_3$$

Eigenschaften von Historien: Übung (2)

| $H:$ | Schritt | T_1 | T_2 | T_3 |
|------|---------|-------|--------------------------|--------------------------|
| 1 | $r(A)$ | | | |
| 2 | | | <u>$w(A)$</u> | |
| 3 | | | $r(B)$ | |
| 4 | $w(B)$ | | | |
| 5 | c | | | |
| 6 | | | | |
| 7 | | | c | $r(A)$ |
| 8 | | | | <u>$w(A)$</u> |
| 11 | | | | c |

| wahr | falsch | Aussage |
|------|--------|-------------|
| X | | $H \in RC$ |
| X | | $H \in ACA$ |
| X | | $H \in ST$ |
| | X | $H \in SR$ |



$RC:$ T_3 liest von T_2 .

$$c_2 < c_3 \vee$$

$ACA:$ — — —

$$c_2 < t_3(A) \vee$$

$ST:$ $w_2(A) < w_3(A)$

aber $c_2 < w_3(A)$

Datenbank-Scheduler

Der Datenbank-Scheduler **ordnet** die (eingehenden) **Elementaroperationen** der Transaktionen so, dass die resultierende Historie bestimmte Eigenschaften hat.

Hilfe: → kann T_n abbrechen

Er implementiert ein Synchronisationsverfahren und sorgt so für **kontrollierte Nebenläufigkeit**.

Synchronisationsverfahren

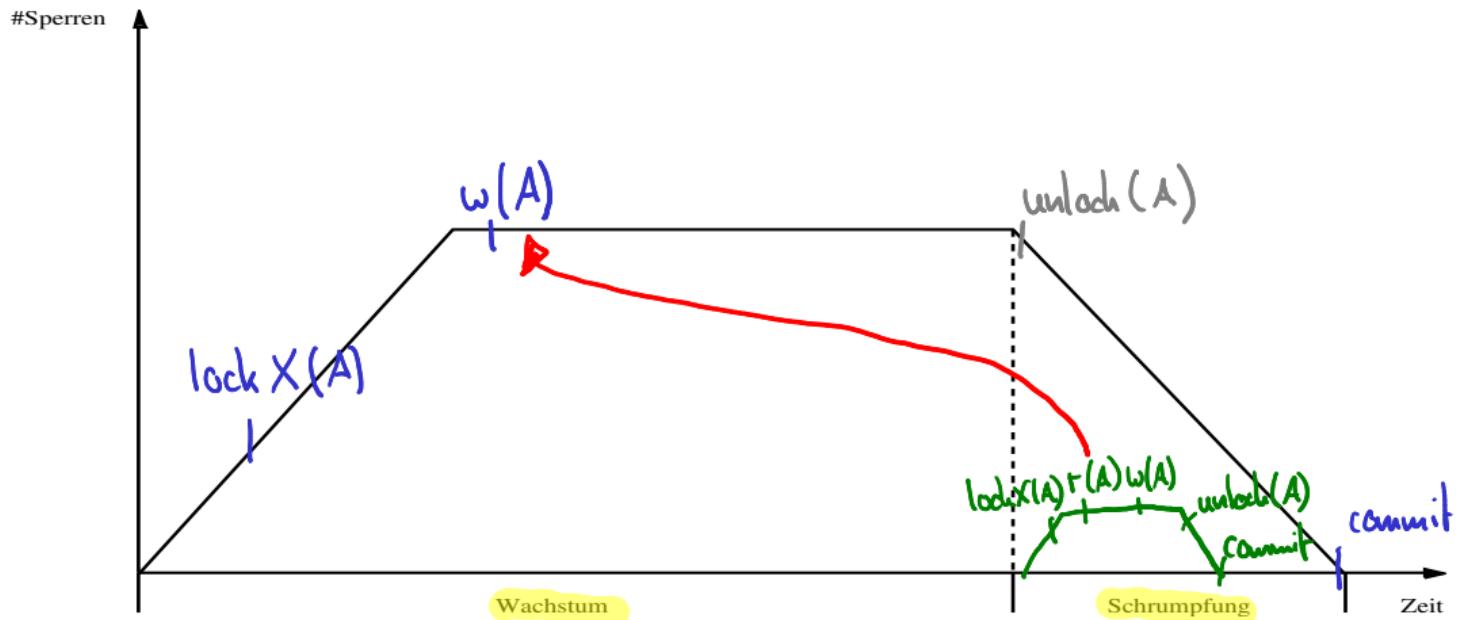
Pessimistisch

- ▶ Sperrbasiert $\text{lock}_S(x)$ vor $r(x)$, $\text{lock}_X(x)$ vor $w(x)$, $\text{unlock}(x)$
 - ▶ 2PL Two Phase Locking
 - ▶ Strenges 2PL
- ▶ Zeitstempel-basiert jede Tx bekommt einen (eindäutigen) Zeitstempel

Optimistisch

- ▶ inkl. abgeschwächter Form: Snapshot Isolation $\text{WriteSet}(T_{\text{andere}}) \cap \text{WriteSet}(T_i) = \emptyset$
- Lesephase (Änderungen nur lokal, keine Änderung an der Datenbasis)
- Validierungsphase: Konflikte mit anderen Tx? $\text{WriteSet}(T_{\text{andere}}) \cap \text{ReadSet}(T_i) = \emptyset$
- Schreibphase: Änderungen werden in die PB angebracht.
zeitlich überlappende Txs

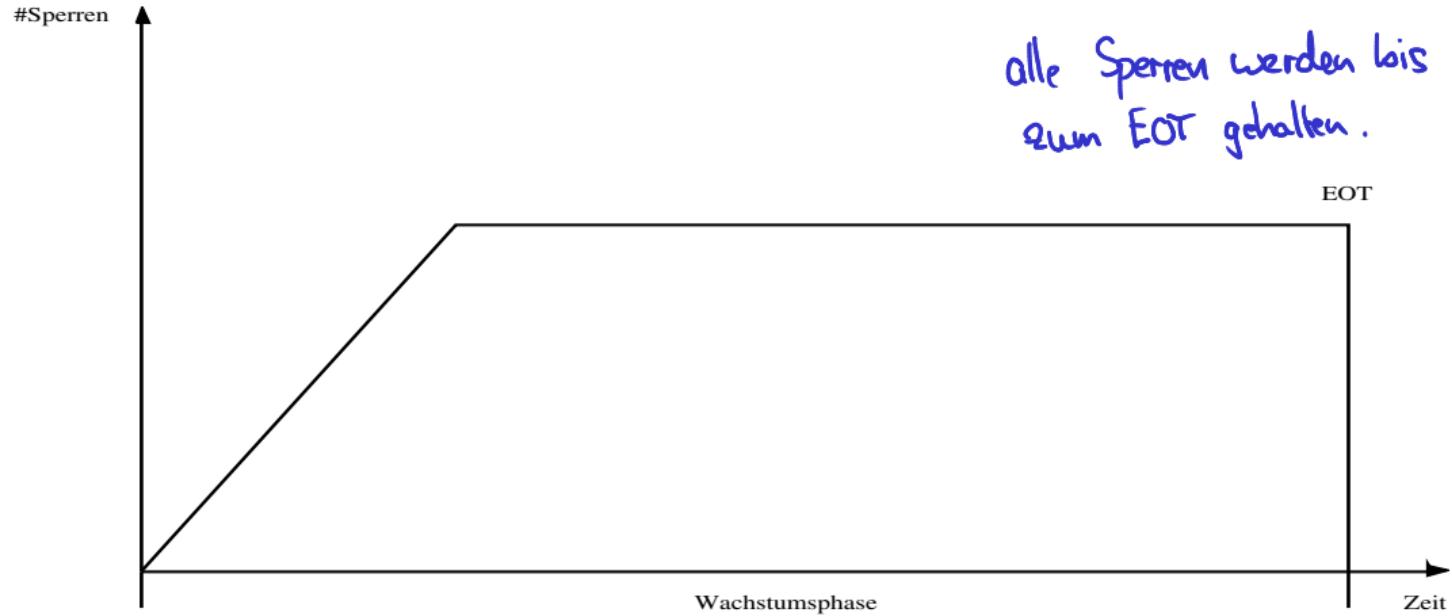
Zwei-Phasen-Sperrprotokoll (2PL)



$T_{grün}$ liegt vor T_{blau}

$c_{grün} <_H c_{blau} \Rightarrow$ nicht RC!

Strenge 2PL

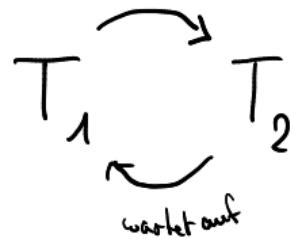


Verklemmung (Deadlock)

Ein Ablauf zweier parallel laufender TAs:

| Schritt | T_1 | T_2 | Bemerkung |
|---------|----------|----------|----------------------|
| 1. | BOT | | |
| 2. | | BOT | |
| 3. | lockX(A) | | |
| 4. | | lockX(B) | |
| 5. | w(A) | | |
| 6. | | w(B) | |
| 7. | lockS(B) | | Wartet auf T_2 ... |
| 8. | | lockS(A) | Wartet auf T_1 ... |

Warte graph:



Zyklus \rightarrow Deadlock

Zwei-Phasen-Sperrprotokoll (2PL)

Deadlockbehandlung

- ▶ **Vermeidung** durch preclaiming
- ▶ **Vermeidung** durch Zeitstempel an Tx
 - ▶ wound-wait
 - ▶ wait-die
- ▶ **Erkennung** durch Wartegraph

$$(\text{T}_{\text{alt}} \rightarrow \text{T}_{\text{jung}}) - (\text{T}_{\text{jung}} \rightarrow \text{T}_{\text{alt}})$$

wound - wait

wait - die

Erweiterbares Hashing

Erweiterbares Hashing

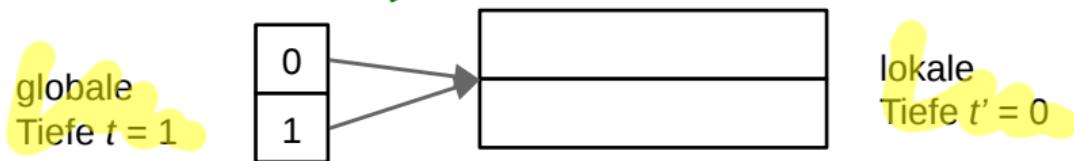
Hashfunktion $h: S \rightarrow B$
Schlüssel Bucket

wir betrachten die **Binärdarstellung** des Hashwerts

$$h(x) = dp$$

Anzahl betrachteter Bits
= globale Tiefe des Dictionaries

Initialer Zustand: (leere HT)

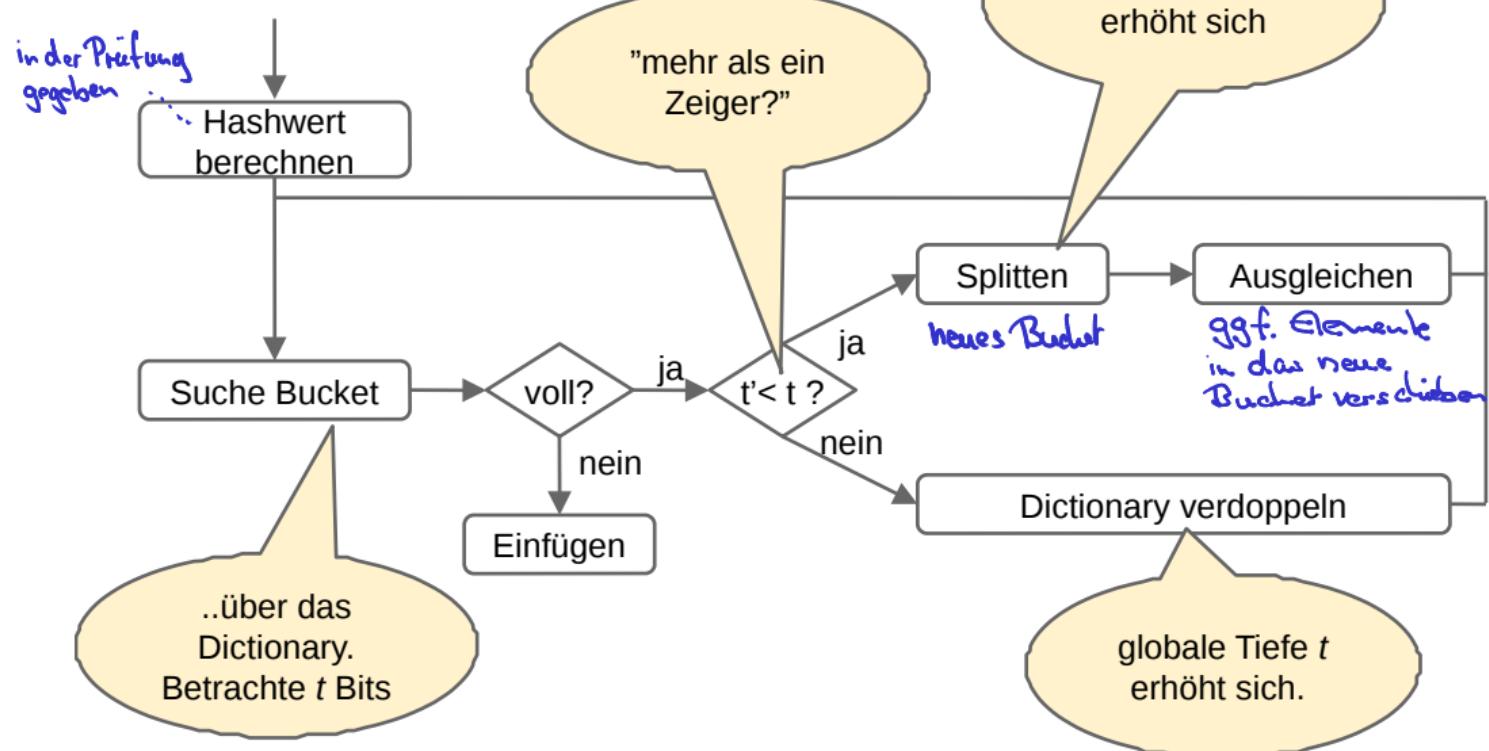


entspricht der
Anzahl der
betrachteten Bits

Dictionary
(Verzeichnis)

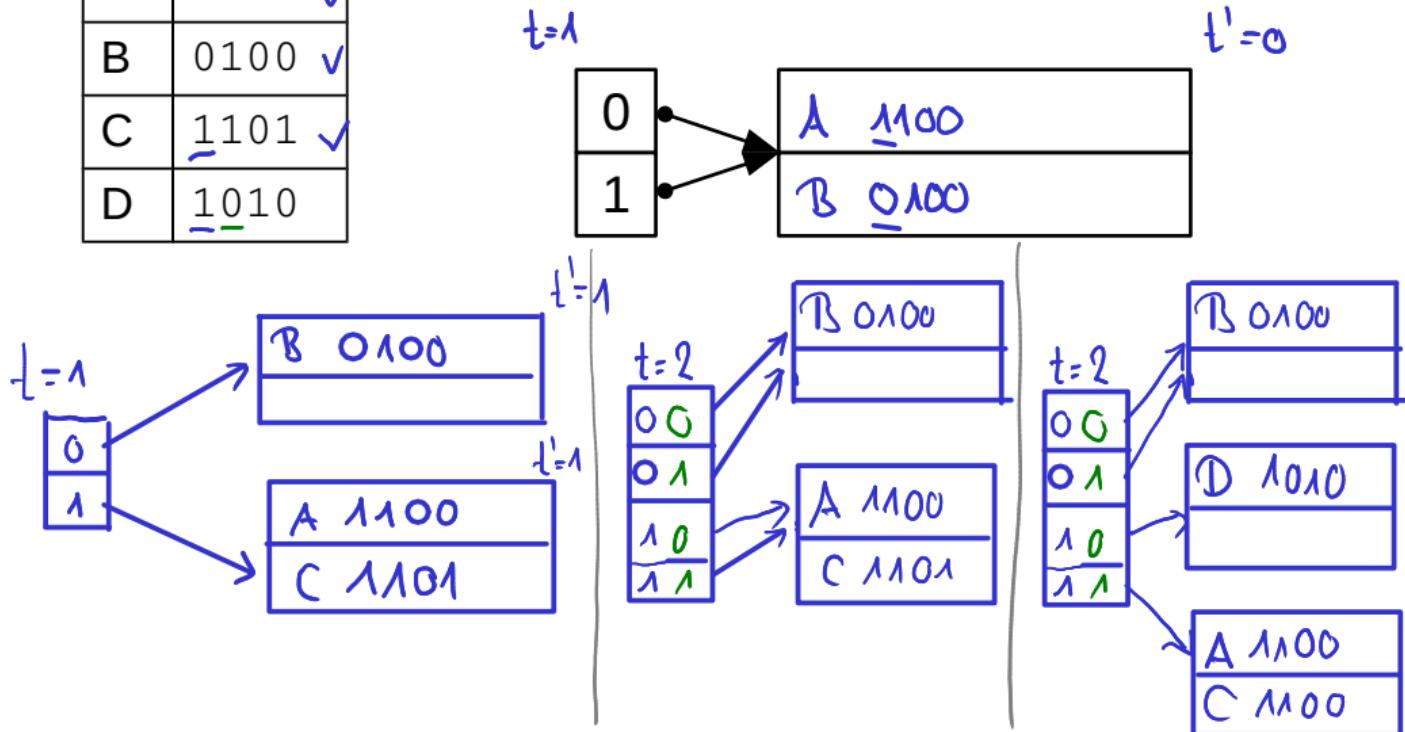
Bucket (Behälter)
Platz für n Einträge
hier $n=2$

Erweiterbares Hashing / Einfügen



Übung: Erweiterbares Hashing / Einfügen

| x | $h(x)$ |
|-----|--------|
| A | 1100 ✓ |
| B | 0100 ✓ |
| C | 1101 ✓ |
| D | 1010 |



Übung: Erweiterbares Hashing / Einfügen

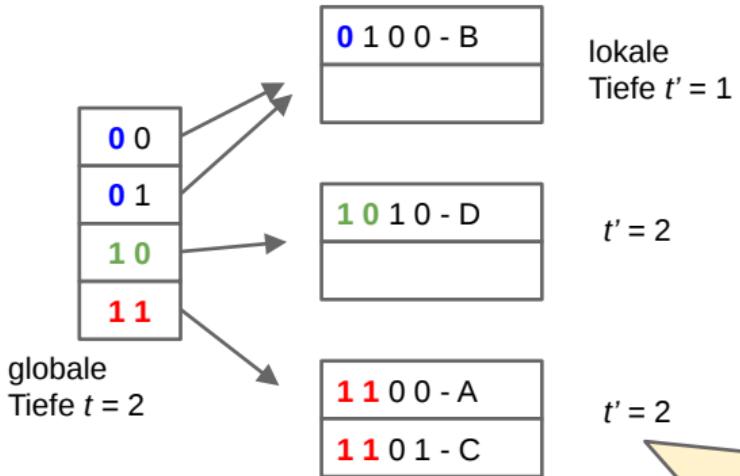
| x | $h(x)$ |
|-----|--------|
| A | 1100 |
| B | 0100 |
| C | 1101 |
| D | 1010 |



Erweiterbares Hashing / Lösung

| x | $h(x)$ |
|-----|--------|
| A | 1100 |
| B | 0100 |
| C | 1101 |
| D | 1010 |

$\overbrace{\quad\quad}$
 $d \quad p$



lokale
Tiefe $t' = 1$

$t' = 2$

$t' = 2$

in einem Bucket mit
Tiefe t' , stimmen
(mindestens) die t'
führenden Bits der
Hashwerte überein

Anfrageoptimierung

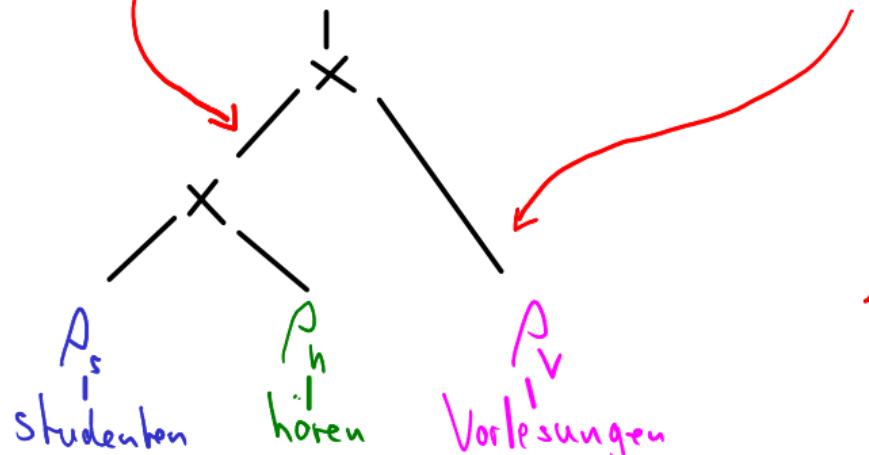
Übung: Anfrageoptimierung

Geben Sie die **kanonische Übersetzung** der folgenden SQL-Anfrage an und optimieren Sie diese logisch:

```
SELECT DISTINCT s.name  
FROM studenten s, hören h, vorlesungen v  
WHERE s.matrnr = h.matrnr  
AND h.vorlnr = v.vorlnr  
AND v.titel = 'Grundzüge'
```

$\Pi_{s.name}$

$s.matrnr = h.matrnr \wedge h.vorlnr = v.vorlnr \wedge v.titel = 'Grundzüge'$



1. Optimierung: Selektionen aufzubrechen und nach unten verschieben.

Übung: Anfrageoptimierung (2)

Angenommen

- ▶ $|s| = 10000$
- ▶ $|h| = 20 * |s| = 200000$
- ▶ $|v| = 1000$
- ▶ 10% der Studenten haben 'Grundzüge' gehört

Dann ergeben sich

- ▶ $|s \times h \times v| = 10000 \cdot 20 \cdot 10000 \cdot 1000 = 2 \cdot 10^{12}$

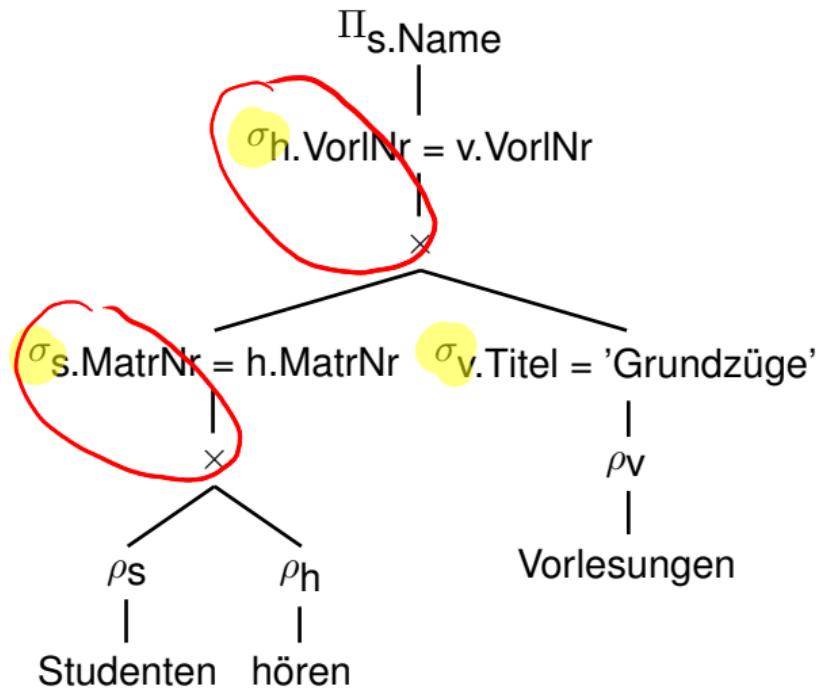
Nach der Selektion verbleiben noch

- ▶ $|\sigma_p(s \times h \times v)| = 0,1 \cdot |s| = 1000$

Übung: Anfrageoptimierung (3)

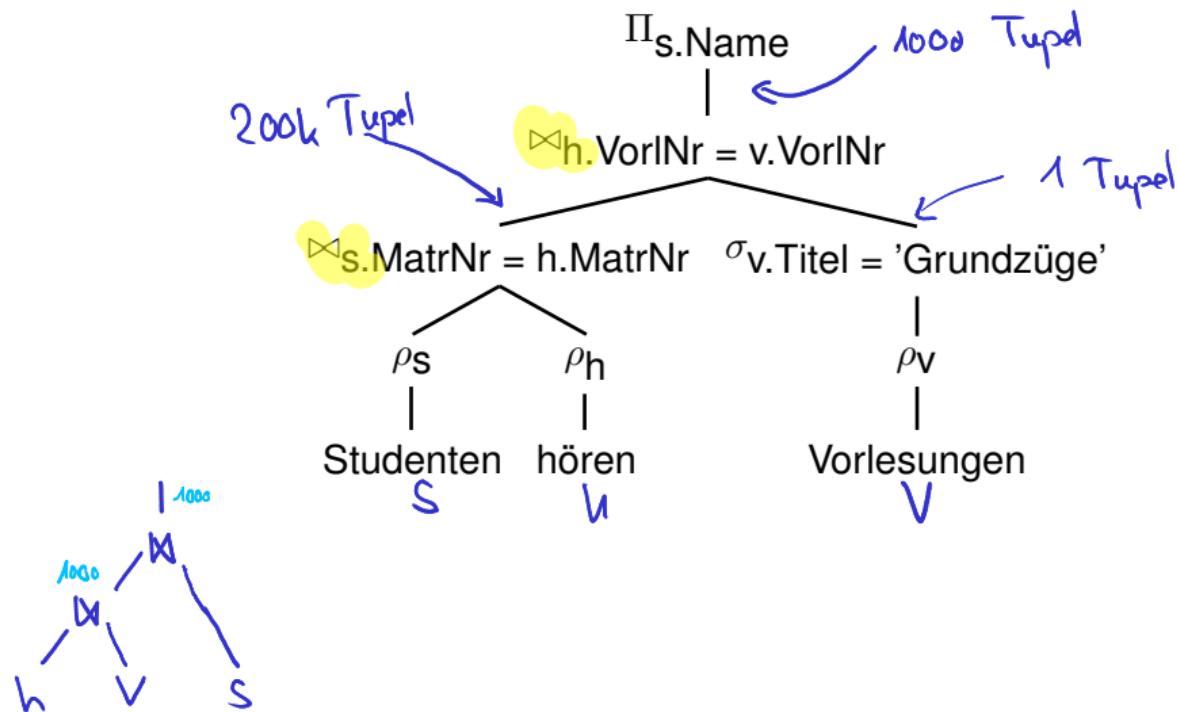
Optimierung 1: Selektionen frühzeitig ausführen (*push selections*):

$$\sigma_p (R \times S) \\ = R \bowtie_p S$$



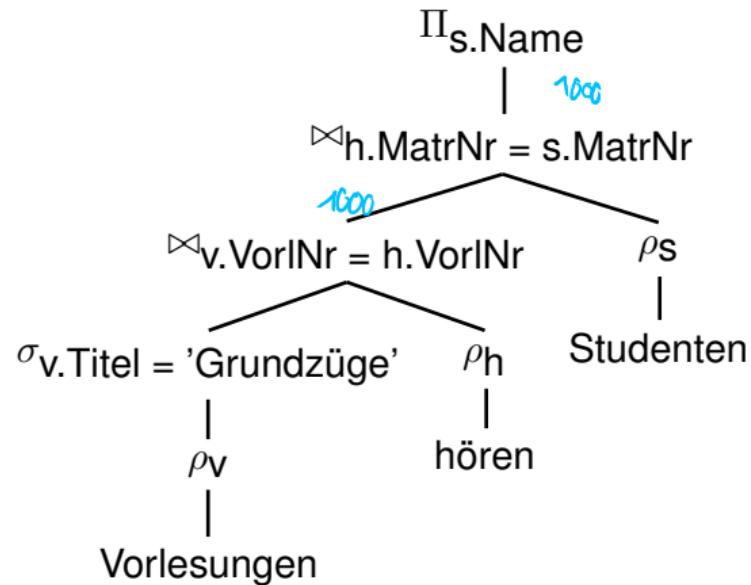
Übung: Anfrageoptimierung (4)

nach Optimierung 2: Kreuzprodukte durch Joins ersetzen (*introduce joins*):



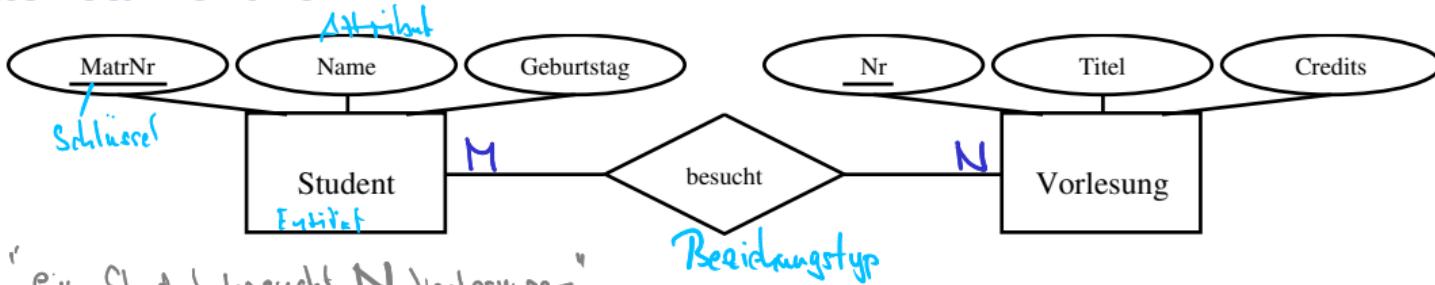
Übung: Anfrageoptimierung (5)

nach **Optimierung 3:** Joinreihenfolge optimieren (*join order optimization*), so dass die Zwischenergebnismengen möglichst klein sind:

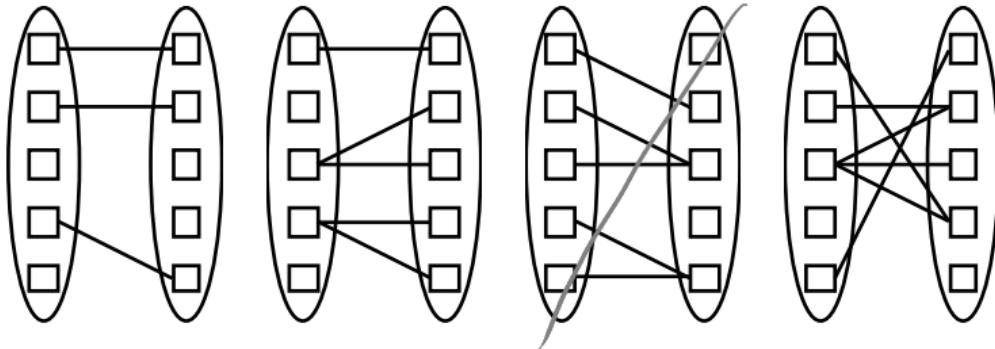


Datenbankentwurf

Datenbankentwurf



Funktionalitäten (Integritätsbedingungen)



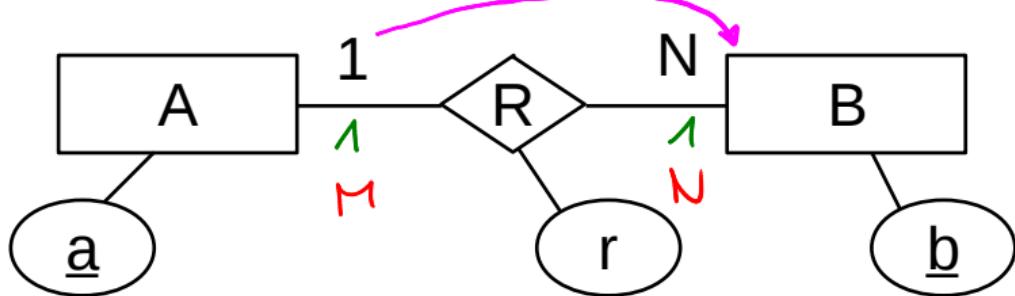
1:1

1:N

N:1

M:N

ER-Modell in Schema überführen und verfeinern



Schema:

$A: \{\underline{a}\}$

$B: \{\underline{b}\}$

$R: \{\underline{a}, \underline{b}, r\}$

—

—

—

Verfeinern: $A:N$

$A: \{\underline{a}\}$

$B: \{\underline{b}, a, r\}$

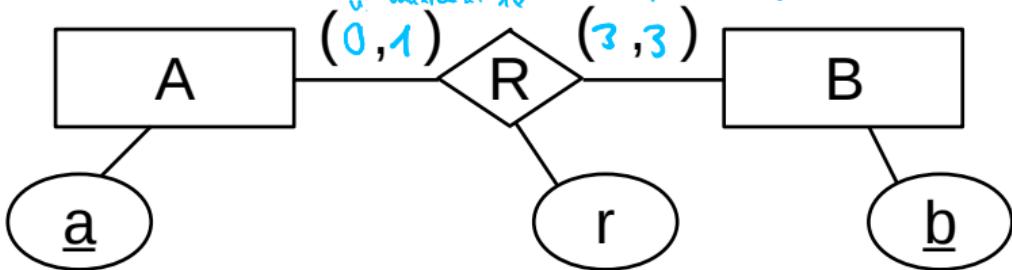
/

(Min,Max) - Angaben

für Integritätsbedingungen

jedes A minimal 0x
maximal 1x

jedes B genau 3x



| R | | |
|----|----|---|
| a | b | r |
| a1 | b1 | |
| a2 | b1 | |
| a3 | b1 | |
| a4 | b2 | |
| a5 | b2 | |
| a6 | b2 | |

1x { } 3x

Relationale Algebra

Algebraische Operatoren:

| | |
|-------------------------|--|
| Projektion | Π_{A_1, \dots, A_n} |
| Selektion | σ_p |
| Kreuzprodukt | \times |
| Verbund (Join) | $\bowtie_\theta, \bowtie_\theta, \bowtie_\theta, \bowtie_\theta, \bowtie_\theta, \bowtie_\theta, \bowtie_\theta, \bowtie_\theta$ |
| Mengenoperationen | \cup, \cap, \setminus |
| Division ! | \div wichtig für All-quantifizierung |
| Gruppierung/Aggregation | $\Gamma_{A_1, \dots, A_n, a_1.f_1, \dots, a_m.f_m}$ |
| Umbenennung | ρ_N , oder $\rho_{a_1 \leftarrow b_1, \dots, a_n \leftarrow b_n}$ |

$$* ' \setminus \text{Differenz} = ' -$$

Minus

Anmerkung: Natural-Join vs. allgemeiner Theta-Join

$A: \{a, x\}$

$B: \{b, x\}$

$$\text{sch}(A \bowtie B) = \{a, b, x\}$$

$$\text{sch}(A \bowtie_{A.x=B.x} B) = \{a, b, x, x\}$$

| | Natural | Theta |
|-------|---------------------------------|--|
| Inner | \bowtie | \bowtie_θ |
| Outer | $\bowtie, \bowtie^L, \bowtie^R$ | $\bowtie_\theta, \bowtie_{\theta^L}, \bowtie_{\theta^R}$ |
| Semi | \bowtie, \bowtie^L | $\bowtie_\theta, \bowtie_{\theta^L}$ |
| Anti | \bowtie^R, \bowtie^L | $\bowtie_\theta, \bowtie_{\theta^L}$ |

► Natural

- Implizite Gleichheitsbedingung auf gleichnamigen Attributen
- Die gleichnamigen Attribute tauchen im Ergebnis nur einmal auf (inner und outer).

► Theta

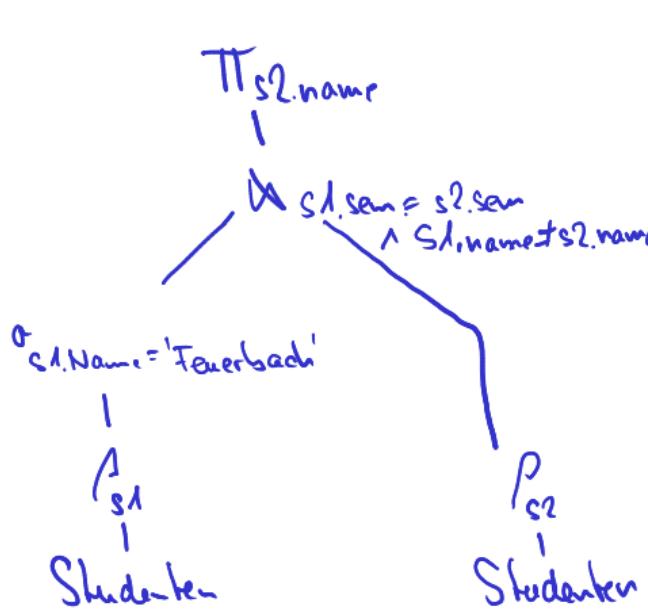
- Explizite (beliebige) Joinbedingung: θ .
- Im Falle von Inner- und Outer-Join werden alle Attribute der beiden Eingaberelationen in das Ergebnis projiziert.

$\bowtie_{S.MatrNr = h.MatrNr \wedge \dots}$

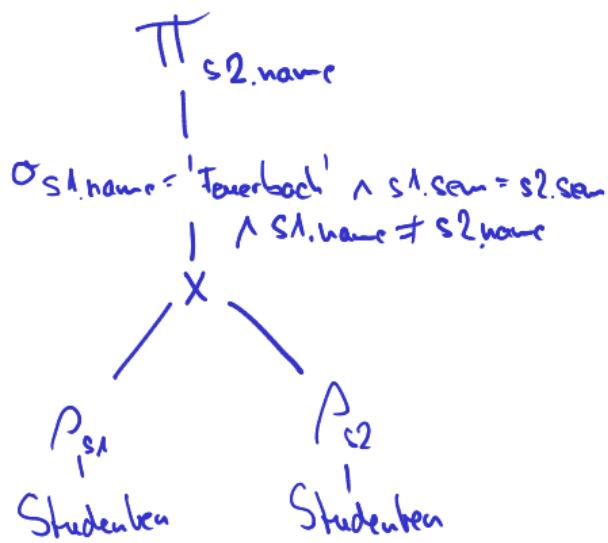
Übung: Relationale Algebra (1)

Finde Studenten (nur Namen ausgeben), die im gleichen Semester sind wie Feuerbach.

"suche Gary" ;)



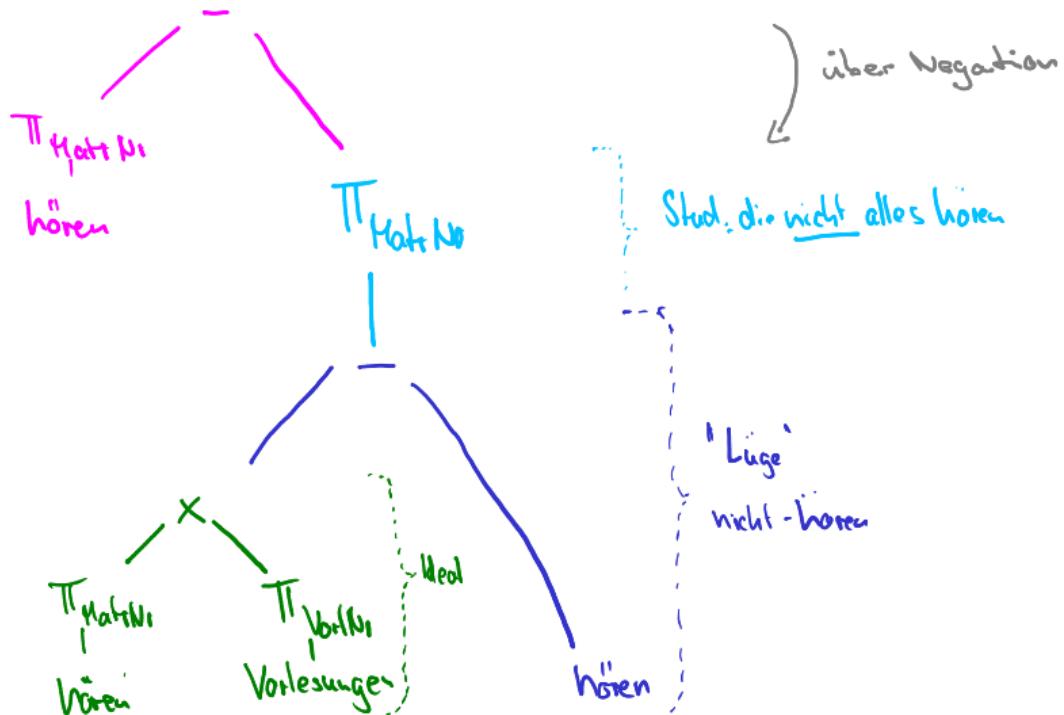
logisch \equiv



Übung: Relationale Algebra (2)

All-quantifizierung

Finde Studenten (nur MatrNr ausgeben), die alle Vorlesungen gehört haben.



$$\text{hören} \rightarrow \Pi_{\text{Vorl.Nr}} (\text{Vorlesungen})$$

$$\text{schemal } (\{[\text{Matr.Nr}, \text{Vorl.Nr}]\} \div \{[\text{Vorl.Nr}]\}) = \{[\text{Matr.Nr}]\}$$

Relationale Entwurfstheorie

Relationale Entwurftheorie

Funktionale Abhangigkeiten (kurz FDs, fur functional dependencies):

- ▶ Seien α und β Attributmengen eines Schemas \mathcal{R} .
- ▶ Wenn auf \mathcal{R} die FD $\alpha \rightarrow \beta$ definiert ist, dann sind nur solche Auspragungen R zulassig, fur die folgendes gilt:
 - ▶ Fur alle Paare von Tupeln $r, t \in R$ mit $\underline{r.\alpha} = \underline{t.\alpha}$ muss auch gelten $\underline{r.\beta} = \underline{t.\beta}$.

Mat+Nr. → Name

Übung: Relationenausprägung vervollständigen

FD - Sudokus

Gegen seien die folgende Relationenausprägung und die funktionalen Abhängigkeiten. Bestimmen Sie zunächst x und danach y , sodass die FDs gelten.

- 1) $B \rightarrow A$
- 2) $AC \rightarrow D$

| | A | B | C | D |
|---|--------|---|---|--------|
| 0 | 7 | 3 | 5 | 8 |
| 1 | $x\ 1$ | 4 | 2 | 8 |
| 2 | 7 | 3 | 6 | 9 |
| 3 | 1 | 4 | 2 | $y\ 8$ |

The diagram illustrates the functional dependencies B → A and AC → D. Blue arrows point from B to A and from AC to D. Handwritten annotations show x1 in red at row 1, column 2, and y8 in red at row 3, column 5.

Funktionale Abhangigkeiten

Seien $\alpha, \beta, \gamma, \delta \subseteq \mathcal{R}$

Axiome von Armstrong:

- ▶ **Reflexivitat:**

Falls $\beta \subseteq \alpha$, dann gilt immer $\alpha \rightarrow \beta$

trivial

- ▶ **Verstarkung:**

Falls $\alpha \rightarrow \beta$ gilt, dann gilt auch $\alpha\gamma \rightarrow \beta\gamma$

- ▶ **Transitivitat:**

Falls $\alpha \rightarrow \beta$ und $\beta \rightarrow \gamma$ gelten, dann gilt auch $\alpha \rightarrow \gamma$

i.d.R. sind nicht alle geltenden FD angegeben;
| insbesondere nicht die trivialen

Mithilfe dieser Axiome konnen alle geltenden FDs hergeleitet werden.

Sei F eine FD-Menge. Dann ist F^+ die Menge aller geltenden FDs (Hulle von F)

Funktionale Abhangigkeiten

Nutzliche und vereinfachende Regeln:

- ▶ **Vereinigungsregel:**

Falls $\alpha \rightarrow \underline{\beta}$ und $\alpha \rightarrow \underline{\gamma}$ gelten, dann gilt auch $\alpha \rightarrow \underline{\beta\gamma}$

- ▶ **Dekompositionsregel:**

Falls $\alpha \rightarrow \beta\gamma$ gilt, dann gilt auch $\alpha \rightarrow \beta$ und $\alpha \rightarrow \gamma$ ↓
und umgedreht
gilt auch

- ▶ **Pseudotransitivitatsregel:**

Falls $\alpha \rightarrow \beta$ und $\gamma\beta \rightarrow \delta$ gelten, dann gilt auch $\gamma\alpha \rightarrow \delta$

Schlüssel

$$R \cdot \{ A, B, C, D \}$$

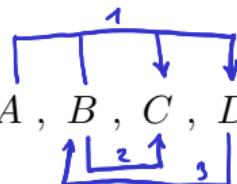
z.B. $\{AB\} \rightarrow R$
 $\{A\} \rightarrow R$

- ▶ **Schlüssel** identifizieren jedes Tupel einer Relation R eindeutig.
- ▶ Eine Attributmenge $\alpha \subseteq R$ ist ein **Superschlüssel**, gdw. $\alpha \rightarrow R$
- ▶ Ist α zudem noch minimal, ist es auch ein **Kandidatenschlüssel** (meist mit κ bezeichnet)
 - ▶ Es existiert also kein $\alpha' \subset \alpha$ für das gilt: $\alpha' \rightarrow R$
- ▶ I.A. existieren mehrere Super- und Kandidatenschlüssel.
- ▶ Man muss sich bei der Realisierung für einen Kandidatenschlüssel entscheiden, dieser wird dann **Primärschlüssel** genannt.
- ▶ Der triviale Schlüssel $\alpha = R$ existiert immer.

denn: $R \rightarrow R$

Übung: Schlüsseleigenschaft von Attributmengen ermitteln

- Ob ein gegebenes α ein Schlüssel ist, kann mithilfe der Armstrong Axiome ermittelt werden (i.A. zu aufwendig!)
- Besser: Die **Attributhülle** $AH(\alpha)$ bestimmen.



- Beispiel: $\mathcal{R} = \{ A, B, C, D \}$, mit $F_{\mathcal{R}} = \{ AB \rightarrow CD, B \rightarrow C, D \rightarrow B \}$

Ist D ein Superschlüssel?

$\rightarrow AH(\{D\})$: ① $\xrightarrow{3} B, D \xrightarrow{2} B, C, D \stackrel{\neq \mathcal{R}}{\text{kein Schlüssel in } \mathcal{R}}$

$AH(\{A, D\})$: $AD \xrightarrow{3} ABD \xrightarrow[oben]{2} ABCD = \mathcal{R} \quad \checkmark \text{ Schlüssel in } \mathcal{R}$

$AH(\{A, B, D\})$: $\checkmark \text{ Schlüssel, da Teilmenge } \{AD\} \text{ bereits ein Schlüssel ist.}$

\hookrightarrow sicher kein Kandidaten schlüssel, weil nicht minimal

Mehrwertige Abhängigkeiten

multivalued dependencies (MVDs)

“Halb-formal”:

- ▶ Seien α und β disjunkte Teilmengen von \mathcal{R}
- ▶ und $\gamma = (\mathcal{R} \setminus \alpha) \setminus \beta \rightarrow \alpha \cup \beta \cup \gamma = \mathcal{R}$
- ▶ dann ist β mehrwertig abhängig von α ($\alpha \twoheadrightarrow \beta$), wenn in jeder gültigen Ausprägung von \mathcal{R} gilt:
 - ▶ Bei zwei Tupeln mit gleichem α -Wert kann man die β -Werte vertauschen, und die resultierenden Tupel müssen auch in der Relation enthalten sein.

Wichtige Eigenschaften:

- ▶ Jede FD ist auch eine MVD (gilt i.A. nicht umgekehrt)
- ▶ wenn $\alpha \twoheadrightarrow \beta$, dann gilt auch $\alpha \twoheadrightarrow \gamma$ (Komplementregel)
- ▶ $\alpha \twoheadrightarrow \beta$ ist trivial, wenn $\beta \subseteq \alpha$ ODER $\alpha \cup \beta = \mathcal{R}$ (also $\gamma = \emptyset$)

Beispiel: Mehrwertige Abhängigkeiten

Beispiel: $R = \{\text{Professor, Vorlesung, Assistent}\}$



MVD 1 : $\underbrace{\text{Prof}}_{\alpha} \rightarrow \underbrace{\text{Vort}}_{\beta}$

$$(R \setminus \alpha) \setminus \beta = \gamma = \text{Assi}$$

MVD 1 und 2 sind komplementär

| ProfessorIn | Vorlesung | AssistentIn |
|-------------|-----------|-------------|
| K | GDB | Linnea |
| K | WebDB | Linnea |
| K | GDB | Harald |
| K | WebDB | Harald |
| K | ERDB | Linnea |
| K | ERDB | Harald |
| | | |
| | | |
| | | |
| | | |
| | | |
| | | |

+ Assi "Harald" → Zweite Tupel
+ Vort. 'ERDB'

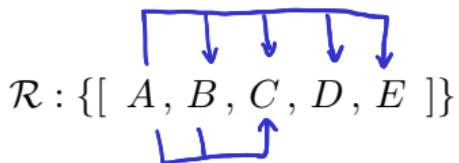
Normalformen: 1NF \supset 2NF \supset 3NF \supset BCNF \supset 4NF

\hookrightarrow 4NF $\frac{g}{s}$

- ▶ **1. NF:** Attribute haben nur atomare Werte, sind also nicht mengenwertig.
 - ▶ **2. NF:** Jedes Nichtschlüsselattribut (**NSA**) ist voll funktional abhängig von jedem Kandidatenschlüssel.
 ▶ β hängt **voll funktional** von α ab ($\alpha \xrightarrow{*} \beta$), gdw. $\alpha \rightarrow \beta$ und es existiert kein $\alpha' \subset \alpha$, so dass $\alpha' \rightarrow \beta$ gilt.
 Bsp: $\mathcal{X} = \{A, B\}$ und es gilt $B \rightarrow C$ ↗
 - ▶ **3. NF:** Frei von transitiven Abhängigkeiten (*in denen NSAe über andere NSAe vom Schlüssel abhängen*).
 ▶ für alle geltenden nicht-trivialen FDs $\alpha \rightarrow \beta$ gilt entweder
 - ▶ α ist ein Superschlüssel, oder
 - ▶ jedes Attribut in β ist in einem Kandidatenschlüssel enthalten
 - ▶ **BCNF:** Die linken Seiten (α) aller geltenden nicht-trivalen FDs sind Superschlüsselelemente.
 - ▶ **4. NF:** Die linken Seiten (α) aller geltenden nicht-trivalen MVDs sind Superschlüsselelemente.

/ | |
 Axiome Definition

Übung: Höchste NF bestimmen



- 1) $A \rightarrow BCDE$
- 2) $AB \rightarrow C$

- 1. NF ✓
- 2. NF ✓
- 3. NF ✓
- BCNF ✓
- 4. NF ✓
- keine der angegebenen

NF1: ✓ keine mengenwertige Attribute

NF2: $K = \{ A \}$ NSA = {BCDE}
nur 1 Attribut
nur 1 K
=> in 2. NF

NF3: ✓ ausführlich $\begin{array}{l} A \rightarrow BCDE \\ \hline \text{ist Superschlüssel} \end{array}$

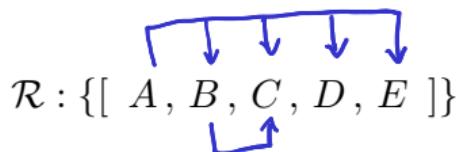
$\begin{array}{l} AB \rightarrow C \\ \hline \text{ist Superschlüssel,} \\ \text{da A Superschl. ist} \end{array}$

BCNF: ✓

NF4: ✓ da in BCNF und keine MVD gegeben.

... die nicht auch FD's sind.

Übung: Höchste NF bestimmen (2)



$$A \rightarrow BCDE$$

$$B \rightarrow C$$

NF1: ✓
NF2: ✓ $K = \{ A \}$ $NSAs = \{ \overbrace{BCDE}^y \}$

NF3: X $B \rightarrow C$
linker Seite
kein Schlüssel rechte Seite
nicht im Kandidaten schlüsseln
enthalten

- 1. NF ✓
- 2. NF ✓
- 3. NF X
- BCNF
- 4. NF
- keine der angegebenen

Weitere Übungsaufgaben → Zu Folien früherer Semester

Schema in 3. NF überführen verlustlos und Abhängigkeitsbewahrend

Synthesealgorithmus

überflüssige Attr. aus den FDs entfernen

- ▶ Eingabe:

- ▶ Kanonische Überdeckung \mathcal{F}_c

- ▶ Linksreduktion •
 - ▶ Rechtsreduktion •
 - ▶ FDs der Form $\alpha \rightarrow \emptyset$ entfernen (sofern vorhanden)
 - ▶ FDs mit gleicher linke Seite zusammenfassen

} der aufwendige Teil

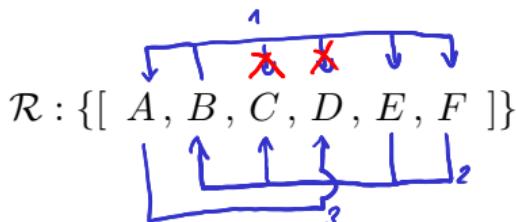
- ▶ Algorithmus:

1. Für jede FD $\alpha \rightarrow \beta$ in \mathcal{F}_c forme ein Unterschema $\mathcal{R}_\alpha = \alpha \cup \beta$, ordne \mathcal{R}_α die FDs $\mathcal{F}_\alpha := \{\alpha' \rightarrow \beta' \in \mathcal{F}_c \mid \alpha' \cup \beta' \subseteq \mathcal{R}_\alpha\}$ zu
2. Füge ein Schema \mathcal{R}_κ mit einem Kandidatenschlüssel hinzu
3. Eliminiere redundante Schemata, d.h. falls $\mathcal{R}_i \subseteq \mathcal{R}_j$, verwirfe \mathcal{R}_i

- ▶ Ausgabe:

- ▶ Eine Zerlegung des unsprünglichen Schemas, wo alle Schemata in 3.NF sind.
 - ▶ Die Zerlegung ist **abhängigkeitsbewahrend** und **verlustfrei**.

Übung: Synthesealgorithmus



- 1) $B \rightarrow ACDEF$
- 2) $EF \rightarrow BC$
- 3) $A \rightarrow D$

$$\chi_1 = \{B\}$$

$$\chi_2 = \{E, F\}$$

$$F_C : \underline{LR} \quad FD2 : \underline{EF} \rightarrow BC$$

$$AH(\{F\}) = \{F\} \not\models \beta$$

$$AH(\{E\}) = \{E\} \not\models \beta$$

$$\begin{aligned} RR: \quad & FD1: B \rightarrow \underline{A} \underline{C} \underline{D} \underline{E} \underline{F} \\ & FD2: EF \rightarrow BC \\ & FD3: A \rightarrow \underline{D} \end{aligned} \quad \left. \right\} F_C$$

Synthese:

Lösung:

$$R_1 : \{ \underline{B}, AEF \}$$

$$R_2 : \{ \underline{EF}, BC \}$$

$$R_3 : \{ \underline{A}, \underline{D} \}$$

gerade enthalten

$$\cancel{R_X : \{B\} \text{ oder } \{E, F\}}$$

eliminiere

Schema in BCNF überführen

BCNF-Dekompositionsalgorithmus (nicht abhängigkeitsbewahrend)

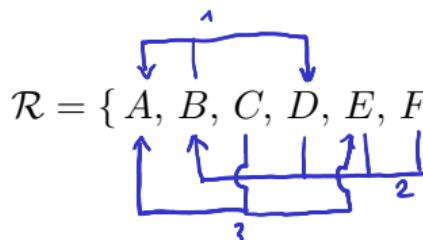
- Starte mit $Z = \{\mathcal{R}\}$
- Solange es noch ein $\mathcal{R}_i \in Z$ gibt, das nicht in BCNF ist:
- Finde eine FD $(\alpha \rightarrow \beta) \in F^+$ mit
 - $\alpha \cup \beta \subseteq \mathcal{R}_i$ (FD muss in \mathcal{R}_i gelten)
 - $\alpha \cap \beta = \emptyset$ (linke und rechte Seite sind disjunkt)
 - $\alpha \rightarrow \mathcal{R}_i \notin F^+$ (linke Seite ist kein Superschlüssel) \rightarrow BCNF verletzt
 - Zerlege \mathcal{R}_i in $\mathcal{R}_{i.1} := \alpha \cup \beta$ und $\mathcal{R}_{i.2} := \mathcal{R}_i - \beta$
 - Entferne \mathcal{R}_i aus Z und füge $\mathcal{R}_{i.1}$ und $\mathcal{R}_{i.2}$ ein, also
$$Z := (Z - \{\mathcal{R}_i\}) \cup \{\mathcal{R}_{i.1}\} \cup \{\mathcal{R}_{i.2}\}$$

Schema in 4.NF überführen

4NF-Dekompositionsalgorithmus (nicht abhängigkeitsbewahrend)

- ▶ Starte mit $Z = \{\mathcal{R}\}$
- ▶ Solange es noch ein $\mathcal{R}_i \in Z$ gibt, das nicht in 4NF ist:
 - ▶ Finde eine **MVD** $\alpha \twoheadrightarrow \beta \in \mathcal{F}^+$ mit
 - ▶ $\alpha \cup \beta \subset \mathcal{R}_i$ (FD muss in \mathcal{R}_i gelten)
 - ▶ $\alpha \cap \beta = \emptyset$ (linke und rechte Seite sind disjunkt)
 - ▶ $\alpha \rightarrow \mathcal{R}_i \notin \mathcal{F}^+$ (linke Seite ist kein Superschlüssel)
 - ▶ Zerlege \mathcal{R}_i in $\mathcal{R}_{i.1} := \alpha \cup \beta$ und $\mathcal{R}_{i.2} := \mathcal{R}_i - \beta$
 - ▶ Entferne \mathcal{R}_i aus Z und füge $\mathcal{R}_{i.1}$ und $\mathcal{R}_{i.2}$ ein, also
 $Z := (Z - \{\mathcal{R}_i\}) \cup \{\mathcal{R}_{i.1}\} \cup \{\mathcal{R}_{i.2}\}$

Übung: BCNF-Dekompositionsalgorithmus



$$R = \{A, B, C, D, E, F\}, F_R = \{B \rightarrow AD, DEF \rightarrow B, C \rightarrow AE\}$$

Finde eine FD, die die BCNF verletzt:

- $B \rightarrow AD$:

 ↑
 kernschlüssel

 Zerlege in

 dann wird
 B Schlüssel

$$R_1 := \{B, A, D\} \quad R_2 := \{B, C, E, F\}$$

\sqcup_3

FD 2 geht verloren

FD 3 "teilweise"

 FD 3: $C \rightarrow AE$

 Dekomp. regel

 FD 3': $C \rightarrow A$

 FD 3'': $C \rightarrow E$

- $C \rightarrow E$:

 ↑
 kernschlüssel
 Zerlege in

$$R_{2,1} := \{C, E\} \quad R_{2,2} := \{B, C, F\}$$

\sqcup_3

\Rightarrow trivialer Superschlüssel,

 da nur noch triviale
 FDs gelten.

Kennzeichnungen ;)

Fragen ?

Wir wünschen viel Erfolg. :-)